GPT 모델의 이해와 활용 chatGPT와 함께하는 미래 소재 개발의 시작! day 1

최재웅 박사 한국과학기술연구원 계산과학연구센터 2023.08.16





About Me


- 최재웅 (Jaewoong Choi)
 - ✓ 산업공학 박사 (2022, SCL@konkuk university, advisor: Janghyeok Yoon)
 - ✓ (Past) Development of machine learning (ML) and natural language processing (NLP)-based system for patent analytics
 - Computer Science, applications; Information science & management 분야 SCI 논문 10건 이상 게재, 국내 특허 등록 2건/ 출원 5건, …
 - Projects: 기술가치 평가모델 (KIBO), 특허인용추천모델, 특허유지기간 예측모델 (KISTI), 자동이슈 탐지모델 (KISTI), 노이즈 특허 필터링 시스템, 데이터 자동수집 파이프라인 및 데이터베이스 설계 (LX)
 - ✓ Techniques: data science; machine learning; natural language processing; relational database; ···





About Me

- ❖ 최재웅(jwchoi95@kist.re.kr)
 - ✓ 박사후 연구원 (2022 ~ 현재), KIST 계산과학연구센터 (advisor: Byungju Lee)
 - ✓ (Now) Applying ML & NLP for materials science literature to extract information such as materials, properties, and synthesis with regard to battery, catalysts, and so on.









About Me

Current works

- Quantitative topic analysis of materials science literature using natural language processing (under review; 1st author)
- ✓ Deep Learning of Electrochemical CO2
 Conversion Literature Reveals
 Research Trends and Directions
 (published in JMCA (2023); co-author)
- ✓ Accelerated materials language processing enabled by GPT (submitted; 1st author)



개체명 인식





Today Contents

* Natural Language Processing (NLP) 소개

❖ Language Model (LM) 방법

❖ Transformers의 등장

❖ BERT & GPT의 비교





1장 Natural Language processing 소개

GPT 모델의 이해와 활용 chatGPT와 함께하는 미래 소재 개발의 시작 day 1






1. Definition of NLP I. NLP 소개

Natural Language Processing (NLP; 자연어처리)

- ✓ NLP는 언어학, 통계학, 그리고 컴퓨터 사이언스(기계학습, 빅데이터 처리, …)를 포함한다!
- ✓ Layers of
 - Phoneti
 - Morphol
 - Syntax
 - Semanti
 - Pragmat
 - Discour:






2. Importance of NLP

I. NLP 소개


NLP 뭘 할 수 있는가

✓ 기계번역, 텍스트 분류, 감성 분석, 음성 인식, 자동 요약, 질의응답 시스템, 챗봇, 정보 추출, 텍스트 생성 등의 다양한 task에서 높은 성능을 보임

NLP 응용 분야 예시



GPT가 제공하는 기능





3. Development of NLP

I. NLP 소개

* NLP 기술의 발전

- 소기: 규칙 기반과통계적 접근 방식 →복잡성 다양성 해결 X
- ✓ Deep learning 발전:
 Word2vec 과 같이,
 dense embedding
 시도
- ✓ Transformer 등장:
 RNN 계열 모델 한계
 해결 + Attention
 mechanism





2장 Language model

GPT 모델의 이해와 활용 chatGPT와 함께하는 미래 소재 개발의 시작 day 1






1. Language Model 소개

II. Language Model

- 언어모델은 주어진 단어(토큰)들의 시퀀스(문장 혹은 문서)에 대한 임베딩 (벡터) 표현을 통해, 주제 찾기, 감성 분류, 개체명 인식, 기계 번역, 요약 등의 문제를 풀 수 있음
 - ✓ 아래와 같은 텍스트 생성의 경우, 주어진 문장에서, 다음 단어가 얼마나 자연스러운지 확률적으로 계산하여, 출현하기 적합한 단어를 예측할 수 있음





ATIONAL SCIENCE
CH CENTER
of Science and Technology

1. Language Model 소개

II. Language Model

- 통계적 언어모델(Statistical Language Model; SLM)
 - ✓ 자연어를 모델링하기 위해, 단어 시퀀스(문장)에 확률을 할당
 - 가장 일반적인 모델링은 이전 단어들을 주고, 다음 단어를 예측

$$P(w_1, w_2, w_3, w_4, w_5, \dots w_n) = \prod_{n=1}^n P(w_n | w_1, \dots, w_{n-1})$$

P(미래 소재 개발의 시작)

= P(미래) × P(소재I미래) × P(개발의I미래 소재) × P(시작I미래 소재 개발의)

⇒ 희소성 문제 (sparsity problem): 코퍼스에 없으면 풀 수 없다.





1. Language Model 소개

II. Language Model

How to Model Language

- ✓ 단어의 임베딩을 목표: Bag of words에서 Neural Network 기반으로
 - Word2vec, FastText ~ Glove
 - CNN 계열:TextCNN, TextCapsulNet, ··· 주로 텍스트 분류를 목표
- ✓ sequence 데이터 처리 목표: seq2seq 단방향/양방향 ~ 번역 문제!
 - 통계(조건부 확률) 기반 언어모델 (아주 옛날)
 - RNN, LSTM series ~ BiLSTM
 - Transformer 기반: Autoencoding, Autoregressive, Seq2Seq
 - BERT series, GPT series, BART, ELECTRA, …






2. 단어의 임베딩

II. Language Model


Skip-gram/CBOW Model (Word2Vec)

✓ 중심 단어로 주변단어를 예측하거나(Skip-gram), 주변 단어로 중심단어를 예측(CBOW)하는 Neural Networks 모델 기반

CBOW



Skip-Gram target word context word



I like natural language processing






2. 단어의 임베딩

II. Language Model

Skip-gram/CBOW Model (Word2Vec)



유사한 위치에 있는 단어는 비슷한 의미를 가질 것이다!

벡터 간 연산(Subtraction)은 단어 간의 관계를 나타낼 수 있음!!





3. Seq2Seq 모델


II. Language Model

- * Seq2Seq (단방향/양방향) 언어 모델링
 - ✓ 번역 문제처럼, Input sequence를 넣으면 output sequence가 산출되는 형태

You like natural language processing



✓ Sequential한 데이터 형태를 반영하는 모델 필요! → RNN, LSTM, GRU 등등 사용








3. Seq2Seq 모델

II. Language Model

* Seq2Seq (단방향/양방향) 언어 모델링

- ✓ Seq2Seq 모델은 크게 encoder와 decoder로 구성
 - Encoder는 입력 문장의 모든 단어들을 sequential 하게 입력 받은 뒤에, 압축하여 하나의 Context vector로 만듦
 - Decoder는 Context vector로부터 번역된 단어를 하나씩 순차적으로 출력함








3. Seq2Seq 모델

II. Language Model

* Seq2Seq (단방향/양방향) 언어 모델링

- ✓ RNN, LSTM, GRU 계열 모델 문제점
 - 하나의 고정된 크기의 벡터(context vector)에 모든 정보를 압축 ~ 정보 손실
 → seq2seq with attention (2014, 조경현 교수님 bb)
 - RNN 모델 구조 특성 상 연속적인 tanh 연산에 따른 Vanishing gradient 문제
 - → LSTM, GRU 등의 모델 등장



Advances in neural information pro입력 시퀀쇼의 모든 정보를 하나의 벡터로 (2015). 표현 → Information Loss





3장 Transformer

GPT 모델의 이해와 활용 chatGPT와 함께하는 미래 소재 개발의 시작 day 1






Ⅲ. Transformer 소개

- ❖ RNN 계열의 모델들을 대체하자!
 - ✓ 왜냐면 병렬 처리가 어렵기 때문!
 - 이전 state의 계산 결과를 다음 state에서 사용하는 RNN 구조 때문 (Sequential computation)

그림 5-8 RNN 계층의 순환 구조 펼치기



• RNN 계열은 input 시퀀스와 output 시퀀스 간의 단어 대응 관계를 잘 학습하지 못함 (물리적 거리가 먼 경우) ~ Global dependency라고 논문에서 표현






Ⅲ. Transformer 소개

Transformer의 등장

- ✓ Self Attention mechanism으로 다 바꾸자
 - 병렬 처리의 어려움 해결
 - 시퀀스 데이터를 순차적으로 처리할 때 발생하는 계산 복잡도와 연산량 해결
 - 입력 시퀀스의 각 단어들이 다른 단어들과 얼마나 관련되어 있는지를 계산
- ✓ 인코더와 디코더가 텍스트 시퀀스를 이해하고 생성하는 과정
 - BERT, GPT 등 대부분의 언어모델의 전신



Attention is All You Need (2017)



Ⅲ. Transformer 소개

* Transformer의 등장

- ✓ Global dependency를 고려하자
 - 기존 seq2seq with attention 모델은 attention을 통해 input과 output을 대응함
 - Transformer에서는 self attention을 통해 입력 시퀀스/ 출력 시퀀스 내부 단어 간 대응을 이름










Ⅲ. Transformer 소개


Transformer의 등장

- ✓ RNN 계열은 병렬 처리가 불가능했다
 - 이전 state의 결과를 다음 state에서 input으로 사용하기 때문에, sequence information을 hidden state에 반영하기 위해서 단어별로 계산해야 하기 때문
- ✓ Transformer는 병렬 처리가 가능하다
 - Self-attention으로 입력 시퀀스 내 각 단어 간의 관계를 한번에 계산
 - Position-wise FFNN 형태 (단어별로 독립적으로 적용됨)
 - Position encoding 정보 사용(순차정보 없이 단어 순서 인식)











2. Attention과 Transformer 아키텍처 이해

Ⅲ. Transformer 소개

- Transformer consists of N modules (Encoder-Decoder)
 - ✓ Seq2Seq 구조 그대로! REMIND
 - Machine translation 예시 참고
 - Encoder의 역할: input sequence의 정보를 압축!
 - Decoder의 역할: output sequence를 생성!









2. Attention과 Transformer 아키텍처 이해

Ⅲ. Transformer 소개

Output

Probabilities

Softmax

Linear

Add & Norm

Transformer 내 attention의 역할

✓ Encoder: Multi-head attention ~ BERT 모델로

✓ Decoder: Masked Multi-head attention ~ GPT 모델로

✓ Encoder-Decoder Attention


KEY, VALUE는 encoder에서, QUERY는 decoder에서




Encoder Self-Attention



Masked Decoder Self-Attention







2. Attention과 Transformer 아키텍처 이해

Ⅲ. Transformer 소개

RESEARCH CENTER Korea Institute of Science and Technology

Transformer I am a student <EOS> Output **Probabilities** Softmax Linear Add & Norm Feed Forward Add & Norm Add & Norm Multi-Head Feed N× Forward Add & Norm $N \times$ Masked Multi-Head Multi-Head Attention Positional Positional Encoding Encoding Output Input Embedding Embedding Inputs Outputs **SOS> I am a student** COMPUTATIONAL SCIENCE

나는 학생이다

(shifted right)

26



4장 BERT와 GPT

GPT 모델의 이해와 활용 chatGPT와 함께하는 미래 소재 개발의 시작 day 1





0. Transformer를 활용한 LM

N. BERT & GPT

Transformer-based LMs

- ✓ Seq2Seq:
 - Encoder + Decoder
 - → T5, BART, Pegasus
- ✓ Autoencoding:
 - Encoder
 - → BERT series, ELECTRA
- ✓ Autoregressive
 - Decoder
 - → GPT series, XLNet





Figure 3-8. An overview of some of the most prominent transformer architectures





Autoencoding Model

- ✓ Trying to reconstruct the original sequence
- ✓ Examples: BERT series model, ELECTRA
- ✓ Natural Bidirectional context, Independent predictions, Artificial Noise



X Fine-tuning discrepancy caused by [MASK] tokens (not in real data)


Assumes cat and yarn are independent, which is wrong


X No joint probability between masked entries




BERT (Bidirectional Encoder Representations from Transformers)

- ✓ BERT uses the encoder of Transformer.
 - base model: 12 layers, 768 dimensions, 12 heads
 - large model: 24 layers, 1024 dimensions, 16 heads
- ✓ Task:
 - MLM ~ [MASK] token, NSP ~ [SEP] token
 - Attention mask 1 for real token, 0 for padding token





(b) Single Sentence Classification Tasks: SST-2, CoLA



(d) Single Sentence Tagging Tasks: CoNLL-2003 NER

소재문헌에서의 NLP 예시 (BERT in Materials Science)

ace-ty-lt-ran-sf-eras-e

cl-oni-dine

na-lo-xon-e

- ✓ BERT는 어떤 도메인의 데이터셋에 학습했는지에 따라, downstream works에서의 fine-tuning 모델 성능이 달라짐
- ✓ 도메인 맞춤형 BERT 모델의 필요성
 - 특정 도메인에서의 언어 이해(전문 용어, 관계, 내용); 예를 들어, biomedical 분야는 bio 전용 NLP모델 (BioBERT, PubMedBERT 등) 을 통해 의료 진단, 의약품 효능 분석을 수행함

Biomedical Term	Category	BERT	SciBERT	PubMedBERT (Ou	rs)
diabetes	disease	✓	✓	✓	
leukemia	disease	✓	✓	\checkmark	
lithium	drug	✓	✓	✓	유의미한 tokenizer 차이
insulin	drug	✓	✓	✓	TEILIE LONGINZEI MOI
DNA	gene	✓	✓	✓	+
promoter	gene	✓	✓	\checkmark	
hypertension	disease	hyper-tension	✓	\checkmark	유의미한 downstream works
nephropathy	disease	ne-ph-rop-athy	✓	\checkmark	TEILIE GOWINGLIEGIII WOLKS
lymphoma	disease	l-ym-ph-oma	✓	\checkmark	성능 차이
lidocaine	drug	lid-oca-ine]	✓	✓	00 1101
oropharyngeal	organ	oro-pha-ryn-ge-al	or-opharyngeal	✓	
cardiomyocyte	cell	card-iom-yo-cy-te	cardiomy-ocyte	✓	
chloramphenicol	drug	ch-lor-amp-hen-ico-l	chlor-amp-hen-icol	✓	
RecA	gene	Rec-A	Rec-A	✓	COMPUTATIONAL SCI

acetyl-transferase

clon-idine

nal-oxo-ne



acetyltransferase

clonidine

naloxone

gene


drug

drug



소재문헌에서의 NLP 예시 (BERT in Materials Science)

- ✓ 사례: 소재문헌에 맞춤화된 BERT 모델
 - 도메인 맞춤형 BERT 모델의 필요성 → MatBERT, MaterialsBERT, MatSciBERT, …
 - Tokenizer: Byte Pair Encoding 알고리즘에 따라 전체 데이터 셋 내에 문자열의 상대적 빈도수에 기반하여, 텍스트를 하위 단위로 분할하여 희소성을 줄이고, 효율성을 높임



원본 텍스트: "The electrolyte (Merck) was 1M LiPF6 in a 1:1 (weight ratio) ethylene carbonate: di-methyl carbonate (EC: DMC) mixture."

BERT (일반적인 텍스트(Wikipedia, news 등)로 학습한 모델):

['The', 'electro', '##ly', '##te', '(', 'Me', '##rc', '##k', ')', 'was', '1', 'M', 'Li', '##P', '##F', ...]

MatBERT (소재문헌으로 학습한 모델):


['The', 'electrolyte', '(', 'Merck', ')', 'was', '1', 'M', 'LiFP6', ...]

2. GPT 모델 IV. BERT & GPT

Autoregressive model (Causal LM)

- Using the context word to predict the next word
 - by estimating the probability distribution of a text corpus
- ✓ Examples: XLNet, GPT series

Use context to predict the next word



X Only considers context in one direction







2. GPT 모델 Ⅳ. BERT & GPT

Autoregressive model

- ✓ GPT is N-stacked decoders of Transformer
 - (encoder-decoder attention) also removed
- ✓ GPT consists of unsupervised pre-training and supervised fine-tuning
 - 12 decoder blocks







GPT의 특성

- ✓ Few shot learner로써의 역할
 - 소수의 N 개 혹은 0개로 학습
 - N-shot K-way learning
- ✓ Task description, Example, Input 으로 구성
- ✓ In-context learning
 - 전체 Prompt의 내용으로, 주어진 Context를 이해하고, 답변을 생성
 - → weight update X
 - 즉, 주어진 텍스트 내 패턴을 학습해 결과를 generate하자!

The three settings we explore for in-context learning

Zero-shot

N. BERT & GPT

The model predicts the answer given only a natural language description of the task. No gradient updates are performed.

```
Translate English to French: ← task description

cheese => ← prompt
```

One-shot

In addition to the task description, the model sees a single example of the task. No gradient updates are performed.

```
Translate English to French: ← task description

sea otter => loutre de mer ← example

cheese => ← prompt
```

Few-shot

In addition to the task description, the model sees a few examples of the task. No gradient updates are performed.

```
Translate English to French: 

sea otter => loutre de mer 

peppermint => menthe poivrée

plush girafe => girafe peluche

cheese => 


prompt
```



II. Language Model

❖ 어떤 모델을 사용해야 하는가?

- ✓ Closed-domain task에서는 여전히 BERT 기반의 supervised model들이 여전히 강세
 - Closed-domain task는 question answering, sentiment analysis, machine translation, summarization, information extraction 등 전통적인 task로, 공개 데이터셋 존재







II. Language Model

상 어떤 모델을 사용해야 하는가?

- ✓ Open-domain task에서는 생성형 모델들이 잘 해결하는 문제들이 존재
 - · Open-domain task는 simple arithmetic, fact-based question, common sense reasoning, historical facts, analogy making, visual reasoning 등 잠재적 답변이 존재하는 상황


Dataset	Example	Article / Paragraph
SQuAD	Q: How many provinces did the Ottoman	Article: Ottoman Empire
	empire contain in the 17th century?	Paragraph: At the beginning of the 17th century the em-
	A: 32	pire contained 32 provinces and numerous vassal states. Some
		of these were later absorbed into the Ottoman Empire, while
		others were granted various types of autonomy during the course of centuries.
CuratedTREC	Q: What U.S. state's motto is "Live free	Article: Live Free or Die
	or Die"?	Paragraph: "Live Free or Die" is the official motto of the
	A: New Hampshire	U.S. state of New Hampshire, adopted by the state in 1945. It
		is possibly the best-known of all state mottos, partly because it
		conveys an assertive independence historically found in Amer-
		ican political philosophy and partly because of its contrast to
		the milder sentiments found in other state mottos.
WebQuestions	Q: What part of the atom did Chadwick	Article: Atom
	discover?†	Paragraph: The atomic mass of these isotopes varied by
	A: neutron	integer amounts, called the whole number rule. The explana-
		tion for these different isotopes awaited the discovery of the
		neutron, an uncharged particle with a mass similar to the pro-
		ton, by the physicist James Chadwick in 1932
WikiMovies	Q: Who wrote the film Gigli?	Article: Gigli
	A: Martin Brest	Paragraph: Gigli is a 2003 American romantic comedy film
		written and directed by Martin Brest and starring Ben Affleck,
		Jennifer Lopez, Justin Bartha, Al Pacino, Christopher Walken, and Lainie Kazan.



IPUTATIONAL SCIENCE EARCH CENTER

N. BERT & GPT


- Large Language Model (LLM)
 - ✓ 수십억개 이상의 문장, 웹페이지, 뉴스기사 등의 텍스트 학습, 즉, 사전 훈련(pre-training)을 진행한 언어모델
 - 이후에, 특정 태스크에 맞게 미세 조정(fine-tuning)하여 사용





N. BERT & GPT

- ❖ LLM 앞으로 어떻게 될 것인가 (낙타 농장의 서막,,,)
 - ✓ 폐쇄형 모델(Closed & Heavy) → 개방형 모델(Open Source & Light)







LLM 모델 요약

- Autoencoding Model의 인코딩 정보로, supervised model을 개발하는 것이 여전히 SOTA이고, 필요하다
- Autoregressive Model의 생성 능력으로 open domain task를 푸는 것은 가능하다
- GPT의 in-context learning으로, 복잡한 NLP task를 풀기 위한 전략적인 prompt 설계가 필요하다





감사합니다. Q&A

최재웅 박사
(jwchoi95@kist.re.kr)
한국과학기술연구원 계산과학연구센터





Papers, websites, ...

References

- P4: Deep Learning of Electrochemical CO 2 Conversion Literature Reveals Research Trends and Directions. Journal
 of Materials Chemistry A (2023)
- P7: https://www.purespeechtechnology.com/text-analysis-text-analytics-text-mining/
- P8: https://openai.com/
- P8:Applications of Natural Language Processing | Data Science Dojo
- P9: https://levelup.gitconnected.com/the-brief-history-of-large-language-models-a-journey-from-eliza-to-gpt-4-and-google-bard-167c614af5af
- P13: https://wikidocs.net/21687
- P15: DL] Word2Vec, CBOW, Skip-Gram, Negative Sampling
- P16: Training Word2vec using gensim
- P17: Tshitoyan, Vahe, et al. "Unsupervised word embeddings capture latent knowledge from materials science literature." Nature 571.7763 (2019): 95-98.
- ❖ P19: Day 01 Basics of Sequential Modelling, NLP and Large Language Models(LLM)
- P20-21: Cortes, Corinna, et al. "Advances in neural information processing systems 28." Proceedings of the 29th Annual Conference on Neural Information Processing Systems, 2015.
- P22: https://velog.io/@sujeongim/NLPSeq2Seq-with-Attention
- P23: Bahdanau, Dzmitry, Kyunghyun Cho, and Yoshua Bengio. "Neural machine translation by jointly learning to align and translate." arXiv preprint arXiv:1409.0473 (2014).
- P24, P28: https://techblog-history-younghunjo1.tistory.com/481





Papers, websites, ...

References

- P25: https://huidea.tistory.com/237
- P29, P33-35: Vaswani, Ashish, et al. "Attention is all you need." Advances in neural information processing systems 30 (2017).
- P30: https://techblog-history-vounghunio1.tistory.com/496
- P31: Neural machine translation with a Transformer and Keras | Text | TensorFlow
- P32: https://ratsgo.github.io/nlpbook/docs/language_model/transformers/
- ❖ P33: 16-01 트랜스포대(Transformer) 딥 러닝을 이용한 자연어 처리 입문
- ❖ P40: Aman's Al Journal Primers Autoregressive vs. Autoencoder Models
- ❖ P41, P47: Aman's Al Journal Primers Autoregressive vs. Autoencoder Models
- P42: RUBERT: A Bilingual Roman Urdu BERT Using Cross Lingual Transfer Learning
- ❖ P43: ACM Transactions on Computing for Healthcare (HEALTH) 3, no. 1 (2021): 1-23.
- P44: Trewartha, Amalie, et al. "Quantifying the advantage of domain-specific pre-training on named entity recognition tasks in materials science." Patterns 3.4 (2022).
- P47: https://paperswithcode.com/method/gpt
- P48: Brown, Tom, et al. "Language models are few-shot learners." Advances in neural information processing systems 33 (2020): 1877-1901.
- P51-52: Wei, Jason, et al. "Finetuned language models are zero-shot learners." arXiv preprint arXiv:2109.01652 (2021).
- P53: https://github.com/hollobit/GenAl_LLM_timeline



